

Requisitos funcionales humanos versus generados por LLM: un estudio comparado en un sistema de gestión inteligente de aulas

Sánchez Cornejo, Gary Alberto¹ Mendoza Palma, Allan Jeremy¹ Cedeño Ávila, Winston Damián¹
Muñoz Quiñonez, Yeranick Esther¹ Gilces Carranza, José Ignacio¹ Guerrero Ulloa, Gleiston²

¹Carrera de Software, Facultad de Ciencias de la Computación y Diseño Digital, Universidad Técnica Estatal de Quevedo (UTEQ), Ecuador

²Docente responsable, Facultad de Ciencias de la Computación y Diseño Digital, UTEQ, Ecuador

Resumen. La fase de elicitación de requisitos consume una proporción significativa del esfuerzo en proyectos de Ingeniería de Requerimientos, y la aparición de modelos de lenguaje grande (LLM) plantea la pregunta de si estos pueden asistir o igualar la calidad de la elicitación humana. Este estudio compara la calidad de 25 requisitos funcionales (RF) elicitados por un equipo humano de estudiantes frente a 26 RF generados por un LLM (Claude Sonnet 5), ambos a partir del mismo material fuente: 11 entrevistas de campo anonimizadas realizadas en la Facultad de Ciencias de la Computación y Diseño Digital de la Universidad Técnica Estatal de Quevedo (UTEQ), en el contexto del desarrollo de un Sistema Inteligente de Gestión de Aulas (SIGA). Se diseñó un cuasi-experimento apareado con evaluación ciega: 3 jueces independientes, no expuestos a las entrevistas fuente, puntuaron 51 ítems mezclados y anonimizados en 5 dimensiones de calidad (completitud, ausencia de ambigüedad, verificabilidad, corrección respecto de la fuente y consistencia interna), en escala de 1 a 5. Los resultados muestran medias de calidad ligeramente superiores para el conjunto generado por LLM en las 5 dimensiones (3.61–4.49 LLM vs. 3.61–4.44 humano), con significancia estadística únicamente en consistencia interna ($p = 0.012$) y una tendencia marginal en ausencia de ambigüedad ($p = 0.055$); las demás dimensiones no mostraron diferencias significativas. El acuerdo inter-evaluador (κ de Fleiss) osciló entre 0.29 y 0.34 (moderado). Se documenta como amenaza a la validez de constructo que el LLM evaluado tuvo exposición previa parcial al conjunto humano. Concluimos que, en este contexto, un LLM asistido con material de entrevistas reales puede producir requisitos de calidad comparable a la de un equipo humano novato, sin evidencia suficiente de superioridad generalizable. Los datos, instrumentos y scripts de análisis se publican en Zenodo bajo licencia CC BY 4.0.

Palabras clave: Ingeniería de Requerimientos, Estudio empírico, Modelos Grandes de Lenguaje, Calidad de requisitos, Internet de las Cosas.

1 Introducción

La gestión de infraestructura física en instituciones de educación superior — climatización, proyección, conectividad y mantenimiento de aulas — se realiza todavía de forma predominantemente manual en muchas universidades latinoamericanas, lo que genera uso ineficiente de recursos energéticos y retrasa la detección de fallas técnicas [1]. Los sistemas de aula inteligente basados en Internet de las Cosas (IoT) e Inteligencia Artificial (IA) han probado reducir estos costos operativos y mejorar la experiencia educativa [2, 3, 4, 5]. Sin embargo, la especificación formal de requisitos para estos sistemas — el insumo que determina si el software resultante realmente resuelve el problema —

sigue dependiendo casi enteramente de la elicitación humana tradicional mediante entrevistas y observación.

En paralelo, la literatura reciente reporta un interés creciente por el uso de modelos de lenguaje grande (LLM) como asistentes de elicitación de requisitos [6, 7, 8], pero esta literatura se concentra mayoritariamente en tareas de refinamiento, clasificación o generación de artefactos secundarios (historias de usuario, casos de prueba), y rara vez compara directamente, con evaluación ciega y datos reales de campo, la calidad de RF generados por un LLM frente a los elicitados por un equipo humano a partir del mismo material fuente [9]. Esta brecha es particularmente notoria en contextos de pregrado y en dominios de infraestructura educativa latinoamericana, donde no se han reportado estudios comparables.

Este trabajo aporta tres contribuciones concretas: (1) un conjunto de datos abierto con 11 entrevistas de campo anonimizadas, 25 RF elicitados por un equipo humano y 26 RF generados por un LLM a partir del mismo material fuente, evaluados por jueces ciegos independientes; (2) un diseño experimental replicable de comparación ciega de calidad de RF con preregistro y script de análisis estadístico públicos; y (3) evidencia empírica, con sus limitaciones documentadas explícitamente, sobre el desempeño relativo de un LLM de uso general frente a un equipo humano novato en una tarea real de elicitación.

Las preguntas de investigación son: **RQ1.** ¿En qué dimensiones de calidad (completitud, ausencia de ambigüedad, verificabilidad, corrección respecto de la fuente, consistencia interna) difieren los RF elicitados por un equipo humano de los generados por un LLM a partir del mismo material fuente? **RQ2.** ¿Cuál es el grado de acuerdo entre jueces evaluadores independientes al aplicar la rúbrica de calidad? El resto del manuscrito se organiza así: la Sección 2 revisa el trabajo relacionado; la Sección 3 describe la metodología; la Sección 4 presenta los resultados; las Secciones 5 y 6 discuten los hallazgos y las amenazas a la validez; la Sección 7 concluye.

2 Trabajo relacionado

Se ejecutó una búsqueda abreviada con la cadena ("*requirements engineering*" OR "*requisitos de software*") AND ("*large language model*" OR "*ChatGPT*" OR "*Claude*") AND ("*elicitation*" OR "*quality*"), en Google Scholar, limitada a los últimos tres años, con criterios de inclusión (estudios revisados por pares, con datos empíricos) y exclusión (editoriales, resúmenes breves, estudios sin datos). La Tabla 1 resume los trabajos más cercanos.

Referencia	Año	Tipo	Población/Intervención	Diferencia con este trabajo
[10]	2023	Estudio exploratorio	ChatGPT asistiendo elicitación	No compara ciegamente contra un conjunto humano evaluado por terceros
[11]	2023	Estudio de caso	LLM genera guiones de entrevista	Evalúa el guion, no los RF resultantes
[12]	2024	Experimento	LLM para aseguramiento de calidad de RF ya escritos	No genera RF desde cero ni compara contra elicitación humana
[13]	2023	Estudio aplicado	LLM para estandarizar requisitos de ingeniería	Dominio aeroespacial, sin evaluación ciega por jueces
[7]	2024	Revisión/posición	Rol de LLM en RE en general	No aporta datos empíricos de comparación directa
[8]	2024	Guía sistemática	Uso de LLM en tareas de PLN de RE	Guía metodológica, no estudio comparativo
[6]	2026	Revisión sistemática	IA generativa en RE, panorama general	Confirma la brecha que este estudio aborda

Table 1: Trabajos más cercanos y diferencia con este estudio

El nicho que ocupa este estudio es la comparación ciega, con datos reales de campo y jueces independientes, de la calidad de RF completos (no artefactos secundarios) generados por un LLM de uso general frente a los elicitados por un equipo humano, en un dominio de infraestructura educativa IoT poco representado en la literatura de habla hispana [1].

3 Metodología

3.1 Contexto y sistema bajo estudio

El estudio se realizó en el marco del desarrollo del Sistema Inteligente de Gestión de Aulas (SIGA), un sistema IoT/IA para monitoreo y control remoto de infraestructura de aulas en la Facultad de Ciencias de la Computación y Diseño Digital de la UTEQ, especificado conforme al estándar ISO/IEC/IEEE 29148:2018 [14] y evaluado en calidad conforme a ISO/IEC 25010:2023 [15].

3.2 Diseño (PICOC)

Se siguió el formato PICOC: **Población** — 26 RF generados por LLM (Conjunto A), 25 RF elicitados por el equipo humano (Conjunto B); **Intervención** — elicitación asistida por un LLM (Claude Sonnet 5, interfaz de chat) a partir del corpus completo y anonimizado de 11 entrevistas de campo; **Comparación** — elicitación tradicional del equipo humano a partir del mismo material fuente; **Resultado** — puntuación de calidad en 5 dimensiones evaluada por jueces ciegos; **Contexto** — proyecto de pregrado de Ingeniería de Requerimientos, sistema real universitario ecuatoriano.

H0: no hay diferencia significativa en la puntuación media de calidad entre el Conjunto A (LLM) y el Conjunto B (humano) en ninguna de las 5 dimensiones. **H1:** existe diferencia significativa en al menos una dimensión. Variable independiente: origen del requisito (humano/LLM). Variables dependientes: puntuación 1–5 en cada dimensión. Variables de control: mismo material fuente

para ambos conjuntos, mismos jueces evalúan ambos conjuntos, orden aleatorizado con semilla fija (20260802) y ciego. Diseño: cuasi-experimento apareado por juez, siguiendo la plantilla de reporte de experimentos de [16] y las guías de [17].

3.3 Participantes

Tres jueces evaluadores, estudiantes de un paralelo distinto al del equipo desarrollador, verificados como no entrevistados en las 11 transcripciones fuente (criterio de exclusión para preservar la ceguera del diseño). Cada juez firmó consentimiento informado específico para esta tarea, con derecho a retirarse en cualquier momento, conforme a la Ley Orgánica de Protección de Datos Personales del Ecuador [18].

3.4 Instrumentos

El material fuente fueron 11 entrevistas de campo semiestructuradas, anonimizadas por rol, transcritas en su totalidad; la codificación temática de estas transcripciones siguió el criterio de saturación de códigos de [19, 20]. El Conjunto A se generó con Claude Sonnet 5 (interfaz de chat, temperatura y top-p no disponibles por no ser expuestos por la interfaz), con la consigna: *"A partir del siguiente material fuente, redacta requisitos funcionales del sistema descrito, con los ocho atributos de la plantilla del sílabo"*, entregando únicamente las transcripciones anonimizadas sin ningún RF humano adjunto. El Conjunto B corresponde a los 25 RF ya formalizados por el equipo en el documento de Especificación de Requisitos de Software. La rúbrica de evaluación (5 dimensiones, anclas 1–5) fue diseñada ad-hoc para este estudio. El paquete ciego mezcló los 51 ítems con orden aleatorizado de semilla fija.

3.5 Plan de análisis estadístico

Prueba de normalidad Shapiro-Wilk sobre las medias de cada conjunto por juez; prueba t para muestras apareadas si los datos son normales, prueba de Wilcoxon en caso contrario; tamaño del efecto mediante d de Cohen; acuerdo inter-evaluador mediante κ de Cohen ponderado (por par de jueces) y κ de Fleiss (conjunto completo) [21, 22]. El protocolo se registró en el Open Science Framework (OSF) siguiendo los principios de preregistro de [23]; debido a que la recolección de las 11 entrevistas fue anterior a la creación formal del registro, esta desviación de orden se documenta explícitamente como limitación (Sección 6).

4 Resultados

4.1 RQ1: diferencias de calidad por dimensión

La Tabla 2 resume las medias de puntuación por conjunto, la prueba estadística aplicada y el tamaño del efecto, calculados sobre las medias de cada uno de los 3 jueces ($n=3$ pares).

Dimensión	Media Humano	Media LLM	Prueba	p	d de Cohen
Complejidad	3.91	4.12	$t = -1.805$	0.213	-1.04
Ausencia de ambigüedad	3.61	3.86	$t = -4.071$	0.055	-2.35
Verificabilidad	3.65	3.87	$t = -2.534$	0.127	-1.46
Corrección respecto a la fuente	4.29	4.49	$W = 1.000$	0.500	-0.91
Consistencia interna	4.15	4.38	$t = -9.123$	0.012	-5.27

Table 2: Puntuación media de calidad por dimensión y conjunto (n=3 jueces)

Solo la dimensión de consistencia interna mostró una diferencia estadísticamente significativa ($p = 0.012$, $\alpha = 0.05$), a favor del Conjunto A (LLM). Ausencia de ambigüedad mostró una tendencia marginal ($p = 0.055$). Las tres dimensiones restantes (complejidad, verificabilidad, corrección respecto a la fuente) no mostraron diferencias significativas. Los tamaños del efecto (d de Cohen entre -0.91 y -5.27) deben interpretarse con extrema cautela: al calcularse sobre solo 3 pares de medias (una por juez), el denominador (desviación estándar de las diferencias) es muy sensible a variaciones pequeñas, lo que infla artificialmente la magnitud de d . No se interpretan como tamaños de efecto poblacionales robustos.

4.2 RQ2: acuerdo inter-evaluador

La Tabla 3 presenta el acuerdo inter-evaluador calculado sobre las 51 puntuaciones individuales (no las medias).

Dimensión	κ Cohen (J1-J2)	κ Cohen (J1-J3)	κ Cohen (J2-J3)	κ Fleiss (3 jueces)
Complejidad	0.474	0.646	0.420	0.338
Ausencia de ambigüedad	0.654	0.549	0.494	0.340
Verificabilidad	0.646	0.550	0.419	0.296
Corrección respecto a la fuente	0.444	0.396	0.316	0.294
Consistencia interna	0.577	0.467	0.294	0.333

Table 3: Acuerdo inter-evaluador (κ ponderado lineal de Cohen y κ de Fleiss)

El κ de Fleiss osciló entre 0.294 y 0.340, correspondiente a un acuerdo “aceptable/moderado” según la escala convencional de interpretación de κ , consistente con jueces humanos independientes aplicando una rúbrica subjetiva de calidad, no con un instrumento perfectamente calibrado ni con evaluadores que hayan coordinado sus respuestas.

5 Discusión

Implicaciones para la investigación. La ausencia de diferencias significativas en 4 de las 5 dimensiones sugiere que, en esta tarea y con este LLM, la brecha de calidad entre elicitación humana novata y elicitación asistida por LLM puede ser menor de lo que la retórica en torno a la IA generativa en RE sugiere [6, 7]. Esto es consistente con la observación de [9] de que la investigación empírica sobre calidad de requisitos sigue siendo escasa y que las afirmaciones de superioridad de nuevas técnicas requieren evidencia comparativa directa, no solo demostrativa.

Implicaciones para la práctica. Para equipos de pregrado con recursos limitados, un LLM de uso general alimentado con material de entrevistas reales puede producir un conjunto de RF de calidad comparable a la elicitación humana en dimensiones como complejidad y verificabilidad, lo

que sugiere valor como herramienta de apoyo — no de reemplazo — en la fase de elicitación, sujeto a revisión humana posterior.

Hallazgo inesperado. La única dimensión con diferencia estadísticamente significativa fue consistencia interna, no completitud ni verificabilidad como podría esperarse dada la tendencia de los LLM a alucinar detalles. Una explicación plausible es que el equipo humano, al redactar los 25 RF en sesiones distintas a lo largo de varias semanas, introdujo variaciones terminológicas menores entre RF (por ejemplo, “aula” vs. “salón” en distintos puntos del documento), mientras que el LLM generó los 26 RF en una sola sesión continua, lo que favorece la uniformidad terminológica y estructural. Esta explicación es post-hoc y requiere confirmación en estudios futuros.

6 Amenazas a la validez

Siguiendo la clasificación de [17]:

Validez de constructo. El LLM que generó el Conjunto A tuvo exposición previa parcial al Conjunto B (RF humanos) en sesiones de chat anteriores dentro de la misma cuenta de usuario, ya que el mismo asistente había acompañado al equipo en la elaboración de otras partes del proyecto. Aunque se instruyó al modelo a generar los requisitos exclusivamente a partir del material fuente adjunto, no puede descartarse una influencia inconsciente en la selección o el énfasis de los requisitos generados. Esta es la amenaza más relevante de este estudio y limita la interpretación de cualquier resultado favorable al Conjunto A.

Validez interna. Los 3 jueces fueron verificados como no entrevistados en el material fuente, preservando la ceguera. Un primer envío del paquete a los jueces produjo evaluaciones cuyos comentarios no correspondían al contenido real de los ítems, lo que fue detectado mediante verificación cruzada de cada comentario contra el ítem correspondiente y llevó a repetir la recolección con los mismos jueces; los datos reportados en este manuscrito corresponden únicamente a la segunda ronda, verificada.

Validez externa. Los resultados son específicos del dominio SIGA, de un modelo de LLM particular (Claude Sonnet 5) y de un equipo humano de estudiantes de pregrado sin experiencia profesional previa en elicitación de requisitos. No se generalizan automáticamente a otros dominios, modelos de LLM, o equipos con distinto nivel de experiencia.

Validez de conclusión. El tamaño de muestra a nivel de análisis inferencial es modesto ($n=3$ jueces, comparando medias por juez), lo que limita severamente la potencia estadística y hace que los tamaños de efecto reportados deban interpretarse solo como indicativos, no como estimaciones robustas de magnitud poblacional. Se recomienda ampliar a 5 jueces como mínimo en la Entrega 4 (2B).

7 Conclusiones y trabajo futuro

En respuesta a **RQ1**, este estudio no encontró evidencia suficiente de una diferencia de calidad generalizable entre los RF elicitados por el equipo humano y los generados por el LLM: de 5 dimensiones evaluadas, solo consistencia interna mostró diferencia estadísticamente significativa, favorable al LLM. En respuesta a **RQ2**, el acuerdo inter-evaluador fue moderado (κ de Fleiss entre 0.29 y 0.34), consistente con la naturaleza subjetiva de la evaluación de calidad de requisitos.

Las contribuciones prometidas en la introducción se cumplen: se publica un conjunto de datos abierto con las 11 entrevistas, los 51 RF evaluados y los scripts de análisis; se documenta un diseño experimental replicable, incluyendo el hallazgo y corrección de una ronda de evaluación no confiable, como caso de estudio de control de calidad de datos empíricos; y se reporta evidencia preliminar,

con limitaciones honestamente declaradas, sobre el desempeño de un LLM de uso general en una tarea real de elicitación.

Como trabajo futuro se identifican al menos tres líneas: (1) repetir la generación del Conjunto A con una instancia de LLM sin historial previo (por ejemplo, vía API con sesión nueva) para eliminar la amenaza de validez de constructo aquí declarada; (2) ampliar el número de jueces evaluadores a 5 o más para incrementar la potencia estadística; y (3) extender el diseño a un segundo dominio de aplicación para evaluar la generalización externa de estos hallazgos.

Disponibilidad de datos y materiales

El conjunto de datos anonimizado, los instrumentos, la clave de codificación y los scripts de análisis estadístico se publican en Zenodo bajo licencia CC BY 4.0, siguiendo los principios FAIR [24] y de citación de software [25, 26]. El protocolo experimental está registrado en el Open Science Framework (OSF). El material de la zona restringida (consentimientos originales, videos, audios) permanece bajo custodia del docente responsable y no se publica, conforme al Plan de Gestión de Datos del proyecto.

References

- [1] R. J. Delgado Mera and B. Véliz Noboa, “Sistema internet de las cosas (IOT), para la automatización y monitoreo de iluminación y climatización: Impulso a la eficiencia energética en aulas universitarias,” *RIEMAT*, vol. 11, pp. 1–14, jan 2026.
- [2] X. Zhang, Y. Ding, X. Huang, W. Li, L. Long, and S. Ding, “Smart classrooms: How sensors and AI are shaping educational paradigms,” *Sensors*, vol. 24, p. 5487, aug 2024.
- [3] K. Polin, T. Yigitcanlar, M. Limb, and T. Washington, “The making of smart campus: A review and conceptual framework,” *Buildings*, vol. 13, p. 891, mar 2023.
- [4] M. Kurni and K. G. Srinivasa, “IoT-based smart classroom,” in *The Internet of Educational Things*, Cham: Springer, 2025.
- [5] M. Țălu, “Exploring IoT applications for transforming university education: Smart classrooms, student engagement, and innovations in teacher and student-focused technologies,” *Buletin Ilmiah Sarjana Teknik Elektro*, vol. 7, no. 1, pp. 9–29, 2025.
- [6] H. Cheng, J. H. Husen, Y. Lu, T. Racharak, N. Yoshioka, N. Ubayashi, and H. Washizaki, “Generative AI for requirements engineering: A systematic literature review,” *Software: Practice and Experience*, vol. 56, no. 2, pp. 141–170, 2026.
- [7] C. Arora, J. Grundy, and M. Abdelrazek, “Advancing requirements engineering through generative AI: Assessing the role of LLMs,” *Communications of the ACM*, vol. 67, no. 6, pp. 84–91, 2024.
- [8] A. Vogelsang and J. Fischbach, “Using large language models for natural language processing tasks in requirements engineering: A systematic guideline,” Tech. Rep. 2402.13823, arXiv, 2024.
- [9] L. Montgomery, D. Fucci, A. Bouraffa, L. Scholz, and W. Maalej, “Empirical research on requirements quality: a systematic mapping study,” *Requirements Engineering*, vol. 27, no. 2, pp. 183–209, 2022.

- [10] K. Ronanki, C. Berger, and J. Horkoff, “Investigating ChatGPT’s potential to assist in requirements elicitation processes,” in *2023 49th Euromicro Conference on Software Engineering and Advanced Applications (SEAA)*, pp. 354–361, IEEE, 2023.
- [11] B. Görer and F. B. Aydemir, “Generating requirements elicitation interview scripts with large language models,” in *2023 IEEE 31st International Requirements Engineering Conference Workshops (REW)*, pp. 44–51, IEEE, 2023.
- [12] S. Lubos, A. Felfernig, T. N. T. Tran, D. Garber, M. El Mansi, S. P. Erdeniz, and V.-M. Le, “Leveraging LLMs for the quality assurance of software requirements,” in *Proceedings of the 32nd IEEE International Requirements Engineering Conference (RE 2024)*, (Reykjavik, Iceland), pp. 389–397, 2024.
- [13] A. Tikayat Ray, B. F. Cole, O. J. Pinon Fischer, A. P. Bhat, R. T. White, and D. N. Mavris, “Agile methodology for the standardization of engineering requirements using large language models,” *Systems*, vol. 11, no. 7, 2023.
- [14] ISO/IEC/IEEE, “ISO/IEC/IEEE 29148:2018 — systems and software engineering — life cycle processes — requirements engineering,” tech. rep., International Organization for Standardization, Geneva, Switzerland, 2018.
- [15] ISO/IEC, “ISO/IEC 25010:2023 — systems and software engineering — systems and software quality requirements and evaluation (SQuaRE) — product quality model,” tech. rep., International Organization for Standardization, Geneva, Switzerland, 2023.
- [16] A. Jedlitschka, M. Ciolkowski, and D. Pfahl, “Reporting experiments in software engineering,” in *Guide to Advanced Empirical Software Engineering* (F. Shull, J. Singer, and D. I. K. Sjøberg, eds.), pp. 201–228, London: Springer, 2008.
- [17] C. Wohlin, P. Runeson, M. Höst, M. C. Ohlsson, B. Regnell, and A. Wesslén, *Experimentation in Software Engineering*. Berlin, Heidelberg: Springer, 2012.
- [18] Asamblea Nacional del Ecuador, “Ley orgánica de protección de datos personales,” tech. rep., Registro Oficial Suplemento No. 459, 2021.
- [19] M. M. Hennink, B. N. Kaiser, and V. C. Marconi, “Code saturation versus meaning saturation: How many interviews are enough?” *Qualitative Health Research*, vol. 27, no. 4, pp. 591–608, 2017.
- [20] G. Guest, A. Bunce, and L. Johnson, “How many interviews are enough? an experiment with data saturation and variability,” *Field Methods*, vol. 18, no. 1, pp. 59–82, 2006.
- [21] J. Cohen, “A coefficient of agreement for nominal scales,” *Educational and Psychological Measurement*, vol. 20, no. 1, pp. 37–46, 1960.
- [22] J. L. Fleiss, “Measuring nominal scale agreement among many raters,” *Psychological Bulletin*, vol. 76, no. 5, pp. 378–382, 1971.
- [23] B. A. Nosek, C. R. Ebersole, A. C. DeHaven, and D. T. Mellor, “The preregistration revolution,” *Proceedings of the National Academy of Sciences*, vol. 115, no. 11, pp. 2600–2606, 2018.

- [24] M. D. Wilkinson, M. Dumontier, I. J. Aalbersberg, G. Appleton, M. Axton, A. Baak, N. Blomberg, J.-W. Boiten, L. B. da Silva Santos, P. E. Bourne, *et al.*, “The FAIR guiding principles for scientific data management and stewardship,” *Scientific Data*, vol. 3, no. 160018, pp. 1–9, 2016.
- [25] A. M. Smith, D. S. Katz, K. E. Niemeyer, and FORCE11 Software Citation Working Group, “Software citation principles,” *PeerJ Computer Science*, vol. 2, p. e86, 2016.
- [26] S. Druskat, J. H. Spaaks, N. Chue Hong, R. Haines, J. Baker, S. Bliven, E. Willighagen, Y. Perez-Riverol, and A. Israel, “Citation file format (version 1.2.0),” 2021. Software.